

전 문 석 사 학 위 프 력 티 컴 보 고 서
Master Thesis

LLM을 활용한 비정형 범주형 데이터의
의미론적 표준화 정제 방안 :
산업용 공구 이름 데이터를 중심으로

A Semantic Standardization Cleaning Method of
Unstructured Categorical Data Using LLM :
Focusing on Industrial Tool Name Data

신흥철(申弘徹, Shin Hong-chul)

인공지능
Artificial Intelligence

과학기술연합대학원대학교
UNIVERSITY OF SCIENCE AND TECHNOLOGY

2025 年 12 月

LLM을 활용한 비정형 범주형 데이터의
의미론적 표준화 정제 방안 :
산업용 공구 이름 데이터를 중심으로

A Semantic Standardization Cleaning Method of
Unstructured Categorical Data Using LLM :
Focusing on Industrial Tool Name Data

申弘徹 신흥철

이 報告書를 전문석사學位 請求報告書로 提出함

2025 年 12 月

科學技術聯合大學院大學校
인공지능 專攻

신 흥 철

신흥철 의 인공지능學部
전문석사學位報告書 認准함

2025年 12月

委員長 _____ 印

委 員 _____ 印

委 員 _____ 印

委 員 _____ 印

委 員 _____ 印

科學技術聯合大學院大學校

감사의 글

입학 시점부터 지금까지 제가 나아가야 할 학업의 길에 대한 방향을 설정해주시고 지도해주신 한국전자통신연구원 유윤식 책임연구원님(UST 지도교수)께 존경과 감사의 말씀 드립니다.

더불어, 바쁜 일정에도 불구하고 심사에 참여하시어 앞으로의 학업 방향과 보고서의 완성도를 높이는데 조언을 아끼지 않으신 한국전자통신연구원 허태욱 책임연구원님(UST 교수), 대전대학교 전승현 교수님께도 깊이 감사드립니다.

요약

디지털 시대에서 데이터 품질은 기업 운영의 핵심 요소이나 수동 입력 시 발생하는 비정형의 범주형 데이터는 비일관적인 ‘더티데이터’ 형태로 존재하는 경우가 많아 데이터 분석의 효율성을 저해하고 막대한 운영 비용을 발생시킨다. 특히 동일한 의미를 다르게 표현하는 어휘적 다양성은 머신러닝 모델의 범주 인식 능력을 왜곡시켜 성능저하의 주요 원인이 된다. 본 연구에서는 이러한 문제 해결을 위해 대규모 언어모델(LLM)을 활용한 비정형 범주형 데이터의 의미론적 표준화 방법론을 제안한다. LLM기반의 표준화로써 데이터 정제 과정을 자동화하고 효율성을 극대화하고자 한다. 본 방법론에서는 다양한 오픈소스 LLM 모델을 사용하여 기존의 단순 매칭 기반 방식 대비 데이터의 일관성을 크게 향상시키고 분류 정확도를 유의미하게 개선하였다. 결론적으로 LLM의 의미 이해 능력을 활용한 표준화 프레임워크는 데이터 정제에 소요되는 시간과 비용을 절감하고 데이터기반 의사결정 및 머신러닝 모델 신뢰도를 높이는데 실질적인 기여를 할 것으로 기대된다. 이 연구에서 산업에서 사용되는 공구이름 데이터를 중심으로 하여 비정형 데이터 품질 관리 분야에 효율적인 접근 방식을 제시한다.

주요단어(Keyword) : 비정형 데이터, 데이터 표준화, 대규모 언어모델, 의미론적 표준화, 데이터 품질

SUMMARY

In the digital age, data quality is a key element of a company's operation, but unstructured categorical data generated during manual input often exists in the form of inconsistent 'dirty data', which hinders the efficiency of data analysis and incurs enormous operation costs. In particular, lexical diversity, which expresses the same meaning differently, distorts the category recognition ability of machine learning models and is a major cause of performance degradation. To solve this problem, this study proposes a semantic standardization methodology of unstructured categorical data using a large-scale language model(LLM). By standardizing LLM-based, we intend to automate the data cleaning process and maximize efficiency. In this methodology, various open-source LLM models were used to significantly improve the consistency of data and significantly improve classification accuracy compared to existing simple matching-based methods. In conclusion, a standardization framework using LLM's ability to understand the meaning is expected to make a practical contribution to reducing the time and cost of data cleaning and increasing data-based decision-making and machine learning model reliability. In this study, an efficient approach in the field of unstructured data quality management is presented, focusing on the tool name data used in industry.

Key words : Unstructured data, Data standardization, Large language model, Semantic Standardization, Data quality

목 차

I. 서 론	1
1.1. 연구 배경 및 문제 제기	1
1.2. 기존 방식의 한계점 및 해결책 제시	1
가. 기존 방식과 한계점	1
나. LLM을 활용한 해결책 제시	2
1.3. 연구 목적	2
가. 프로세스 효율성 검증	2
나. 데이터 품질 향상 검증	2
1.4. 학문적 및 실증적 기여	3
II. 관련 연구 및 데이터 문제 정의	3
2.1. 데이터 표준화 최신 연구 동향	3
2.2. 외부데이터를 이용한 RAG 기술 활용	4
2.3. 실험데이터 셋 구축 및 더티데이터 분석	4
가. 데이터셋 구축 및 정답지 확보	4
나. 더티데이터 유형 분류	4
III. 제안 방법론 및 실험 설계	6
3.1. 더티데이터셋 준비 및 정답지 데이터셋 구축과정	6
가. 더티데이터 필터링	6

나. 정답지 데이터셋 구축.....	6
3.2. RAG 아키텍처 및 구현 환경.....	7
가. 시스템 환경 및 모델 명시.....	7
나. 임베딩 모델 선정.....	7
3.3. LLM 프롬프트 설계 및 작동 메커니즘.....	8
가. Few-Shot 프롬프트 상세 설계.....	8
나. RAG 파이프라인 및 메커니즘.....	10
3.4. 성능 평가.....	11
가. 프로세스 효율성 평가.....	11
나. 데이터 품질 평가.....	11
IV. 실험 결과.....	12
4.1. 정확도 비교 및 분석.....	12
가. RAG 방식 평가.....	13
나. 모델 효율성 평가.....	14
4.2. 생성 속도 및 정확도 트레이드오프 분석.....	14
가. 우선순위 상위 모델 분석.....	17
나. 그 외 모델.....	17
4.3. 더티데이터 유형별 정제 성능 분석.....	17
가. LLM 강점 영역.....	20
나. LLM 취약점 영역.....	20
4.4. 실패사례 진단.....	20

4.5. LLM기반 정제 시스템의 실증적 의미.....	21
V. 결 론	21
5.1. 연구 결과 및 시사점.....	21
5.2. 제안 알고리즘의 기대 효과.....	21
5.3. 연구 한계 및 향후 연구 방향.....	22
참고문헌	23

I. 서론

1.1. 연구 배경 및 문제 제기

디지털 전환 시대에서 데이터는 기업 운영의 핵심 자산으로 부상하였다. 그리고 데이터의 가치는 근본적으로 그 데이터의 품질에서부터 시작된다. 그러나 현실에서 사용되는 데이터는 보통 불완전하고 비일관적인 ‘더티데이터’ 형태로 존재한다. 이는 데이터 분석가로 하여금 업무를 진행하는 데 있어서 효율성 측면에서 심각한 병목 현상을 일으킨다. 실제로 데이터 분석가들은 실제 분석 시간에서 50~80%에 달하는 시간을 데이터 수집, 정제, 전처리 등 비작업에서 사용하고, 이는 데이터 기반 의사결정의 신속성을 저해시키는 요소로 작용한다 (Wang et al., 2025 [4]; Kim et al., 2025 [18]; Keeney, 1975 [19]). 특히, 다수의 사용자가 수동으로 입력하는 비정형의 범주 데이터는 데이터 정제 과정의 난이도를 증가시킨다. 예를 들어, ‘충전식드릴’, ‘드릴(배터리)’나 ‘드릴비트’, ‘기리’같이 동일한 의미를 지닌 공구 이름을 다른 어휘로 표현하는 문제는 데이터 정제 과정의 난이도를 증가시킨다(Belcak et al., 2025 [7]; Hwang et al., 2025 [9]; Zhang & Huang, 2024 [12]). 이러한 데이터의 비일관성은 기계 학습 모델링 시 각각의 데이터를 완전히 다른 범주로 인식하게 만든다. 그 결과, 실제로는 몇 개 안 되는 핵심 개념이 여러 개의 무의미한 범주로 분열되는 현상이 발생한다. 이러한 현상은 머신러닝 모델에서 범주형 데이터를 수치화된 방식으로 변경하는 방법 중 하나인 원 핫 인코딩(One-Hot Encoding) 과정 수행 시 고차원의 희소행렬을 생성한다. 이는 모델의 훈련 시간과 메모리 요구량을 급증시키고 결국에는 과적합을 유발하여 일반화 성능을 저해한다(정선우 외, 2023 [14]). 따라서 데이터 분석과 데이터 기반 의사결정을 위해서는 데이터의 정제 과정에서 의미론적 ‘더티데이터’ 문제를 근본적으로 해결하는 것이 중요하다.

1.2. 기존 방식의 한계점 및 해결책 제시

가. 기존 방식과 한계점

기존의 전통적 접근 방식에서는 정규식이나 Okt, KoNLPy와 같은 전통적인 자연어처리 라이브러리 기반의 규칙을 정의해 문제를 해결하

고자 하였다. 그러나 단어 자체에서 예측가능한 구문론적(Syntactic) 오류 처리에 대해서만 한정적인 효율을 보이고, 의미론적(Semantic) 맥락을 이해하지 못한다(Dhakal et al., 2025 [3]; Zhang & Huang, 2024 [12]). 이들은 ‘충전식드릴’과 ‘드릴(배터리)’의 동력원이 충전을 필요로 하는 배터리로 작동하는 드릴임을 추론하거나, 공구 이름 필드에 ‘글루건&심’과 같은 맥락 파악이 필요한 값에 대해서 판단하지 못한다(Glock & Korom, 2025 [10]). 결국 분석가는 예측 불가능한 수많은 예외 케이스 문제를 해결하기 위해 경험 기반의 수작업에 의존하게 된다(Wang et al., 2025 [4]). 이는 분석 과정의 재현성과 결과의 신뢰도를 저해하게 된다.

나. LLM을 활용한 해결책 제시

최근 거대 언어모델(LLM)이 발달하면서 데이터의 의미론적 맥락을 이해하고 추론하는 능력이 데이터 정제 분야에서 새로운 해결책으로 제시되고 있다. LLM은 단순한 패턴 찾기의 수준을 넘어서, 인간의 언어처럼 맥락과 데이터의 겉으로 드러나지 않는 의도를 파악하여 일관적인 표현들을 표준화할 가능성을 갖고 있다. 이는 수작업이나 사전 정의된 규칙 없이 비정형 범주형 데이터를 표준화할 수 있는 가능성을 보여준다(Glock & Korom, 2025 [10]; Nguyen et al., 2023 [15]; Wong et al., 2025 [1]).

1.3. 연구목적

본 연구에서는 LLM의 의미론적 추론 능력을 활용하여, 공구 이름 데이터셋에 기입된 다양한 표현방식에서 의미를 자동으로 탐지하고 표준화하는 지능형 데이터 정제 알고리즘을 설계하여 프로세스 효율성과 데이터 품질의 두 관점에서 효과성을 실증적으로 검증하고자 한다. 세부 목표는 다음과 같다.

가. 프로세스 효율성 검증

데이터 정제에 소요되는 총 생성 시간(토큰 생성 시간으로 한정하여 측정)을 측정하여 제안하는 알고리즘의 생산성 수준을 정량화한다.

나. 데이터 품질 향상 검증

정제 결과물의 정확도(Accuracy), 의미론적 유사도(Semantic Similarity)를 비교해봄으로써 데이터 품질 개선 효과를 확인한다.

1.4. 학문적 및 실증적 기여

핵심적인 학문적 기여는 다음과 같다.

첫째, 데이터 분석 업무의 기본 전제인 ‘원데이터의 불완전성 및 정제 필요성’에 대한 기술적 해결책을 제시한다. 원데이터 수집 및 작성 업무를 맡는 ‘사람’에 의한 데이터 입력 과정의 수많은 오류를 최신 AI 기술을 활용하여 해결하는 데 이 연구의 의미가 있다. 특히, 공구 이름 데이터는 이러한 인적 오류가 집약된 굉장히 ‘더러운’ 데이터이다. 이러한 데이터에 LLM을 적용해 각 모델 별 정제 정확도 및 총 생성 시간을 확인함으로써 데이터정제 과정에서 사용될 수 있는 효율적인 LLM모델을 선택하기 위한 방향을 제시한다.

둘째, 데이터 정제를 ‘구문적 규칙 설계’ 작업에서 LLM을 활용한 ‘의미론적 추론’ 작업으로 전환하는 새로운 패러다임을 ‘RAG 및 Few-Shot 기반의 LLM 정제’라는 구체적이고 재현 가능한 알고리즘으로 제시한다(Wong et al., 2025 [1]; GAN et al., 2025 [6]).

이로써 기존 데이터 정제 연구가 규칙 기반 시스템의 취약성이나 지도 학습의 레이블링 데이터 의존성 등의 한계를 보인 점을 극복하고자 한다.

II. 관련 연구 및 데이터 문제 정의

2.1. 데이터 표준화 최신 연구 동향

기존 데이터 정제 방식에서의 한계를 극복하기 위해 LLM 기반의 데이터 표준화(LLM-based Data Standardization)가 다수 연구되고 있다. LLM은 데이터의 의미를 이해하고 추론하는 능력을 바탕으로, 비정형 텍스트 데이터를 표준화하는 데 효과적이다. 초기에는 주로 Few-Shot 방식의 예시 기반 학습 방식을 사용했다. Few-Shot 방식은 모델이 프롬프트 내에 포함된 제한적인 고품질 예시(Shot)를 참고하여 복잡한 규칙을 학습하도록 유도한다. 하지만 Few-Shot 방식의 경우 몇 개의 예시를 통해 LLM 모델 자체의 일반적인 성능을 보조할 뿐 다수의 공구 이름 데이터와 같은 특정 분야의 모델에는 정확도가 낮고 프롬프트 길이가 길어짐에 따른 비용이 증가하는 문제가 있다.

2.2. 외부데이터를 이용한 RAG 기술 활용

본 연구에서는 공구 이름이라는 특화된 도메인의 데이터 정제를 위해 LLM을 활용한 검색 증강 생성(RAG, Retrieval-Augmented Generation) 방식을 적용해보고자 한다. LLM 자체에서 학습된 데이터 외 외부 자료로부터 만들어진 벡터데이터베이스를 검색하여 LLM에 프롬프트 맥락을 제공함으로써 모델 자체 능력과 외부 지식을 결합하여 정제 정확도를 극대화할 수 있는 방식이다. Few-Shot 방식에서 프롬프트 내에 입력된 제한된 예시만으로 복잡한 규칙을 학습하는 것을 넘어서 사용자가 다루고자 하는 도메인에 특화된 맥락을 참조하여 성능을 향상시킬 수 있다(Ovadia et al., 2024 [16]; Amugongo et al., 2025 [5]; Campo et al., 2025 [8]).

2.3 실험데이터 셋 구축 및 더티데이터 분석

가. 데이터셋 구축 및 정답지 확보

먼저 연구에 사용할 ‘더티데이터’를 확보하였다. 공공데이터포털에서 ‘서울시 대여 공구 찾기 정보’ 데이터셋을 사용하였으며, 이 데이터셋은 각 지역에서 대여 가능한 공구에 대한 정보를 포함하고 있다. 특히 ‘공구이름’ 컬럼은 비정형적이고 비일관적인 입력으로 인해 ‘더티데이터’가 다수 포함되어 있다. ‘공구이름’ 컬럼의 총 11,526행 원본 더티데이터 중 중복을 제거한 3,352개의 고유한 공구 이름 문자열을 최종 분석 대상으로 사용되었다.

나. 더티데이터 유형 분류

연구 대상이 된 공구이름의 정제 전 데이터 컬럼의 비일관성을 체계적으로 분석하기 위해, 더티데이터의 유형을 5가지 대분류와 13가지 세부 유형으로 구성된 종합 분류표를 정의하여 [표1]에 나타내었다. 이 분류표는 LLM 기반 정제 시스템이 해결해야 할 구체적인 문제의 복잡성을 보여준다(Saparina & Lapata, 2024 [11]; Karaca, M. F., 2024 [13]).

대분류 (개수)	세부 유형 (개수)	패턴 정의	데이터 사례
정보 중복형 (1485)	브랜드 혼입 (209)	브랜드명 포함	‘보쉬 pushdrive’ ‘LS 사다리 3단’ ‘250 세신 파이프렌치’
	속성 기입 (946)	규격, 용도, 수량 등 포함	‘180mm 샌더’ ‘드릴날 세트(콘크리트용)’ ‘&글루건(소형)’ ‘6각렌치세트 9개’ ‘L렌치세트(9PCS)’
	동력원 명시 (330)	동력원 정보 포함	‘(20)유선 전동드릴’ ‘(54)미니충전전동드릴’ ‘(54)에어타카’
표준 위배형 (228)	일본어 잔재 (87)	‘기리’, ‘뽀치’ 등 일본어 파생 용어 사용	‘기리세트’ ‘뽀치’
	영문/약어 (30)	‘L렌치’, ‘HSS’ 등 표준화되지 않은 약어/별칭 사용	‘L렌치세트’ ‘HSS쇠톱날’ ‘락킹플라이어(바이스그립)’
	오타자 (111)	단순 오타 및 발음 오류	‘경량몽키’ ‘롱로우즈’ ‘에아컴프레서’ ‘렌치센트’
구조 파괴형 (213)	메타데이터 (147)	목록용 숫자, 분류 불가, 상태 주석 등	‘(1)접톱’ ‘(20,55)드릴비트세트’ ‘(불가)다카핀’ ‘(상자)’
	특수기호 (60)	‘.’, ‘&’, ‘+’, ‘/’, ‘”’ 등 구문 방 해 기호	‘.몽키스패너200mm’ ‘글루건&글루스틱’ ‘드라이버/렌치함’
	인코딩 오류 (6)	문자 깨짐(‘?’) 발생	‘?드럼프’ ‘?치’ ‘가정?차량용 공구세트’
의미 모호형 (213)	복합 명사 (85)	두 개 이상의 공구/기능이 결합 됨	‘충전 드라이버/렌치’ ‘조경가위/양손가위’
	세트/구성품 (230)	주 공구와 세트, 또는 부속품이 함께 기술됨	‘글루건&(심)’ ‘BOSCH 액세스리 드릴 세트’ ‘손타카(핀제공)’
	주/부속품 혼동 (81)	주 공구인지 부속품인지 모호함	‘콘크리트 드릴1’ ‘드라이버 드릴 비트’
비 데이터형 (8)	운영용 텍스트 (8)	제품과 무관한 가격, 연락처, 안 내 문구	‘가정용 공구세트(예약시 전화주 세요. 추가 시 개당 1,000원)’

표 1. 더티데이터 유형 분류

III. 제안 방법론 및 실험 설계

데이터 정제의 기술적 흐름을 명확히 하고, Few-Shot 및 RAG 방식을 활용한 LLM 기반 의미론적 표준화 알고리즘의 구체적인 설계 및 구현 과정을 기술한다.

3.1. 더티 데이터셋 준비 및 정답지 데이터셋 구축 과정

가. 더티데이터 필터링

데이터 분석의 효율성을 위해 공공데이터포털에서 가져온 ‘서울시 대여 공구 찾기 정보.csv’ 원본 11,526개 더티데이터 중에서 중복되는 공구 이름을 제거하여 3,352개의 고유한 더티데이터 셋을 최종 실험 대상으로 확보하였다.

나. 정답지 데이터셋 구축

성능 평가의 기준으로 사용된 ‘정답지’ 데이터셋은 다음 세 가지 요소를 참고하여 연구자가 수동으로 일일이 확인하고 정리하였다.

분류 참고 자료 : 앞서 분류한 13개의 더티데이터 상세 분류 유형, 공구 이름이 작성된 카탈로그, 그리고 네이버 어학사전 등을 참고하였다.

표준화 기준 : 공구의 기능적 측면을 중심으로 분류하였다.

핵심 정보 반영 : 정답지 작성 시, 동력원(에어, 전동, 충전식 등)의 여부, 세트 여부, 공구 유형 및 핵심 용도를 중심으로 정리하여, 작업자가 공구 탐색 시 중요하게 여기는 정보를 최대한 반영하였다. (Christian, N., & Okorie, C., 2013 [17])

3,352개 중 2,330개의 더티 데이터를 확인하였고, 제시된 3가지 기준에 따라 386개의 정답데이터셋을 확보하였다.

3.2. RAG 아키텍처 구현 환경

Few-Shot 방식과 RAG 방식을 비교하여 LLM의 의미론적 정제 능력을 검증하였다.

가. 시스템 환경 및 모델 명시

사용한 오픈소스 LLM 모델은 범용 모델부터 파라미터의 개수 (1B~7.8B), 한국어 특화 여부, 추론형 여부, 양자화 수준(2~16bit)에 따라 11개의 모델을 선정하였다.

나. 임베딩 모델 선정

RAG 검색의 핵심인 벡터 데이터베이스 구축을 위해 허깅페이스에서 한국어 성능을 우선 필터링하여 좋아요 및 다운로드 수가 높은 Sentence-Transformer 모델을 선정하였다.

구분	내용
사용 언어	Python (3.9.13 버전)
구동 환경	Mac Mini M1 (16GB RAM)
LLM 환경	Ollama (0.6.0 버전)
임베딩 모델	Sentence Transformer (Sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2)
벡터데이터베이스	FAISS (Facebook AI Similarity Search)
모델 (11개)	오픈소스 모델 Llama-3.2(3B), Deepseek-r1(1.5B), Gemma(1B, 4B), Exaone(1.2B, 2.4B, 7.8B 등 6종) 상세 모델명 1.Llama - Llama-3.2-Korean-Blossom-3B-gguf-Q4_K_M - Llama-3.2-Korean-Blossom-3B-GGUF:Q2_K 2.Deepseek - deepseek-r1:1.5b 3.Gemma - Gemma3:1b - Gemma3:4b 4.Exaone - Exaone3.5:2.4b - EXAONE-4.0-1.2B-GGUF:Q4_XS - EXAONE-4.0-1.2B-GGUF:BF16 - EXAONE-Deep-2.4B-GGUF:Q4_K_M - EXAONE-Deep-2.4B-GGUF:BF16 - EXAONE-Deep-7.8B-GGUF:Q4_K_M

표 2. 시스템 환경 및 모델

모델	상세 모델명	추론형 여부	한국어 특화	양자화 (bit)	용량 (GB)
Llama	Llama-3.2-Korean-Blossom-3B-gguf-Q4_K_M	X	O	4	2.02
	Llama-3.2-Korean-Blossom-3B-GGUF:Q2_K	X	O	2	1.36
Deepseek	Deepseek-r1:1.5b	O	X	X	1.1
Gemma	Gemma3:1b	X	X	X	0.815
	Gemma3:4b	X	X	X	3.3
Exaone	Exaone3.5:2.4b	X	O	X	1.6
	EXAONE-4.0-1.2-GGUF:IQ4_XS	X	O	4	0.754
	EXAONE-4.0-1.2B-GGUF:BF16	X	O	16	2.56
	EXAONE-Deep-2.4B-GGUF:Q4_K_M	O	O	4	1.64
	EXAONE-Deep-24B-GGUF:BF16	O	O	16	5.34
	EXAONE-Deep-7.8B-GGUF:Q4_K_M	O	O	4	4.77

표 3. LLM 모델 상세 내용

3.3. LLM 프롬프트 설계 및 작동 메커니즘

데이터 정제를 위한 프롬프트는 LLM에게 ‘한국어 하드웨어 공구 이름 분류전문가’의 역할을 부여하고, 구조화된 JSON 출력을 요구하였다.

가. Few-Shot 프롬프트 설계

Few-Shot 프롬프트는 모델 자체에 학습된 지식 기반 추론 능력을 테스트하기 위한 대조군으로 설계되었다.

핵심 규칙 : 표준어 변환(예: ‘기리’ => ‘드릴비트’), 원본 단어 금지, ‘Preprocessed_Name(정제완료된 공구이름 칼럼)’의 띄어쓰기 금지, JSON 전용 출력 요구.

생성 예시 : 프롬프트 내에 6개의 예시를 명시하여, 모델이 ‘هاما’ => ‘해머’, ‘충전’ => ‘무선’, 속성 분리 등을 학습하도록 유도하였다.

작동 방식 : LLM은 이 예시들의 맥락을 파악하여 입력 정답지 데이터에 대한 정제 규칙을 추론하고 JSON을 출력한다.

```
PROMPT_TEMPLATE_FEW_SHOT = """
당신은 한국어 하드웨어 공구 이름 분류 전문가입니다. 당신의 임무는 정제되어있지 않은 공구 이름을 분석하여 구조화된 정보를 추출하는 것입니다.

핵심 규칙 (반드시 준수)
1. 표준어 변환: 모든 공구 이름은 반드시 한국 표준어 및 산업 표준 용어로 변경해야 합니다.
   - 예: 기리 -> 드릴비트, 셋트 -> 세트, 함마/햄머 -> 해머, 밧데리/충전 -> 무선
2. 'Preprocessed_Name'에 저장되는 단어는 띄어쓰기를 하지 않습니다.
   - 예: 공구 세트 -> 공구세트, 드릴 비트 -> 드릴비트
3. JSON 전용 출력: 당신의 출력은 어떠한 추가 텍스트나 설명 없이, 오직 하나의 유효한 JSON 객체여야 합니다.

JSON 스키마는 다음과 같습니다:
{{
  "Preprocessed_Name": "공구의 표준화된 기본 유형입니다. 위의 '핵심 규칙'에 따라 한국산업 표준 용어로 '반드시' 표준화하세요.",
  "Brand": "제조사 또는 브랜드 이름입니다 (예: 보쉬). 없는 경우 null을 사용하세요.",
  "Power_Source": "전원 공급 방식입니다 (예: 무선, 유선, 수동). 없는 경우 null을 사용하세요.",
  "Specification": "전압, 크기, 모델 번호, 수량 등 기타 사양입니다. 관련 없는 마케팅 문구(예: '전화주세요')는 제외하세요."
}}
```

그림 1. Few-Shot 모델 핵심규칙 및 JSON 출력방식 프롬프트

```
Input Name: '보쉬 충전 해머드릴 GSB 18V'
Output:
{{
  "Preprocessed_Name": "해머드릴",
  "Brand": "보쉬",
  "Power_Source": "무선",
  "Specification": "GSB 18V"
}}

Input Name: '12P 3종 기리세트(육각쌍크)'
Output:
{{
  "Preprocessed_Name": "드릴비트세트",
  "Brand": null,
  "Power_Source": null,
  "Specification": "12P 3종, 육각쌍크"
}}

Input Name: '공구세트(25pcs,5개)'
Output:
{{
  "Preprocessed_Name": "공구세트",
  "Brand": null,
  "Power_Source": null,
  "Specification": "25pcs, 5개"
}}
```

그림 2. Few-Shot 모델 데이터 출력 예시 프롬프트




그림 3. Few-Shot 모델 도식화

나. RAG 파이프라인 및 메커니즘

RAG 방식은 Few-Shot 방식의 도메인 지식 부족 한계를 극복하기 위해, 외부의 ‘정답지’ 데이터를 LLM에 활용하도록 검색 증강하는 방식으로 구현되었다.

임베딩 및 벡터 데이터베이스 구축 : 연구자가 제작한 386개의 공구 이름 정답지 데이터셋을 Sentence Transformer 모델을 사용하여 벡터화를 진행했다. 벡터화된 정답지 데이터는 FAISS 벡터 데이터베이스에 저장되었다.

검색 증강 : 3,352개의 더티데이터셋 입력마다 FAISS 벡터 데이터베이스에서 가장 유사한 사례 3개를 유사도를 기준으로 검색했다. 유사한 사례 개수는 토큰 생성 속도와 정확도를 고려하여 임의의 숫자 3개로 설정하였다.

LLM 호출 및 프롬프트 입력 : 검색된 유사 사례 3개는 RAG 프롬프트 템플릿의 {context} 변수에 입력된다. RAG 프롬프트는 Few-Shot과 달리 명시적인 예시를 포함하지 않았다. 대신 LLM에게 “정답 데이터베이스”의 검색 결과를 최우선으로 참고하여 JSON을 생성하도록 명시적으로 요구했다. LLM은 제공된 외부 도메인 지식을 기반으로 Preprocessed_Name, Brand, Power_Source, Specification의 속성명으로 지정하여 4가지 칼럼으로 구성된 JSON 출력을 생성한다. 각각 속성 정제 완료된 공구이름, 공구의 상표, 동력원, 길이/규격/용도/특이 사항의 내용을 데이터로 갖는다.

후처리 및 결합 : LLM이 생성한 JSON 결과에서 정제 완료된 데이터를 추출하여 기존의 더티데이터셋과 병합함으로써, 정제된 데이터셋을 확보하였다. 이후 모든 비교를 위해 정답지 데이터와 정제완료된 공구이름 데이터의 공백은 제거하였다.




그림 4. RAG 모델 도식화

```

PROMPT_TEMPLATE_RAG = """
당신은 한국어 하드웨어 공구 이름 분류 전문가입니다. 당신의 임무는 정제되어있지 않은 공구 이름을 분석하여 구조화된 정보를 추출하는 것입니다.

JSON 스키마는 다음과 같습니다:
{{
  "Preprocessed_Name": "공구의 표준화된 기본 유형입니다. 한국산업 표준 용어로 '반드시' 표준화하세요 (예: 기리 -> 드릴비트, 셋트 -> 세트).",
  "Brand": "제조사 또는 브랜드 이름입니다. 없는 경우 null을 사용하세요.",
  "Power_Source": "전원 공급 방식입니다 (예: 무선, 유선, 수동). 없는 경우 null을 사용하세요.",
  "Specification": "기타 사양입니다. 없는 경우 null을 사용하세요."
}}

[중요] 아래는 당신이 참고해야 할, 입력 데이터와 가장 유사한 **"정답 데이터베이스"**의 검색 결과입니다.
이 정보를 **최우선으로 참고**하여 JSON을 생성하세요.

{context}

이제, 위의 "정답 데이터베이스" 내용을 바탕으로 다음 공구 이름을 분석하고 JSON 출력을 제공하세요.

Input Name: '{tool_name}'
Output:
"""
  
```

그림 5. RAG 모델 핵심규칙 및 JSON 출력 방식 프롬프트

3.4. 성능 평가

가. 프로세스 효율성 평가

LLM 기반 시스템의 자원 집약성을 객관적으로 비교하기 위해 다음 지표를 사용한다.

연산 속도 : 정제 작업 실행 중 발생하는 총 생성 시간(LLM의 토큰 생성 시간)을 측정하여 정량화한다.

나. 데이터 품질 평가

정제 결과가 정답 데이터셋에 얼마나 근접하는지를 전통적인 지표와 의미론적 지표를 모두 사용하여 평가한다.

정확도 기반 지표 : 정제된 결과를 ‘정답 데이터셋’과 비교하여 정확도(Accuracy)를 계산한다.

의미론적 유사도 측정 : 모델이 생성한 결과와 정답지 사이의 의미론적 유사성(Similarity)을 RAG 모델의 벡터임베딩에서 사용한 모델과 동일한 ‘paraphrase-multilingual-MiniLM-L12-v2’을 사용하여 계산된 코사인 유사도를 통해 측정한다. 이를 통해 단순 정답/오답을 넘어선 정제 실패의 질을 정량화한다.

IV. 실험 결과

4.1. 정확도 비교 및 분석

다양한 오픈소스 LLM 모델을 두 가지 정제 방식(Few-Shot, RAG)을 적용하여 3,352개의 고유한 더티데이터 공구 이름에 대한 정제 정확도(Accuracy)를 비교한 결과는 [표4]와 [그림6]에서와 같다.

순위	방법	LLM 모델	정확도 (%)
1	RAG	Llama-3.2-Korean-Blossom-gguf-3B:Q4_K_M	97.88
2	RAG	EXAONE-Deep-7.8B-GGUF:Q4_K_M	97.61
3	RAG	Gemma3:4b	97.58
4	RAG	EXAONE-4.0-1.2B-GGUF:IQ4_XS	96.93
5	RAG	Gemma3:1b	96.75
6	RAG	Exaone 3.5:2.4b	95.26
7	RAG	EXAONE-4.0-1.2B-GGUF:BF16	94.06
8	RAG	EXAONE-Deep-2.4B-GGUF:Q4_KM	81.53
9	RAG	EXAONE-Deep-2.4B-GGUF:Q4_BF16	79.86
10	RAG	Deepseek-r1:1.5b	62.68
11	RAG	Llama-3.2-Korean-Blossom-3B-GGUF:Q2_K	55.91
12	Few-Shot	Exaone 3.5:2.4b	39.17

표 4. 오픈소스 LLM 모델 별 공구 이름 더티데이터 정제 정확도




그림 6. 방법론별 공구 이름 정제 정확도 비교 그래프

가. RAG 방식 평가

분석 결과, RAG 기반 LLM 모델들은 Few-Shot 방식 대비 압도적인 성능 우위를 보였다. Few-Shot Exaone 3.5:2.4b 모델의 정확도는 39.17%에 그친 반면, RAG 방식의 상위 모델들은 95% 이상의 매우 높은 정확도를 기록했다(최고 97.88%). 이는 비정형 범주형 데이터 표준화와 같이 도메인 전문성이 요구되는 작업에서, 프롬프트 내 소수의 예시만으로는 복잡한 의미론적 및 구문론적 규칙을 학습하기 어렵다는 것을 보여준다. 반면, RAG는 외부의 ‘정답 데이터베이스’의 맥락을 검색 증강하여 LLM에 제공함으로써, 모델 자체의 능력에만 의존하는 것이 아니라 도메인에 특화된 외부지식을 활용하여 정제 작업을 수행한다. 이 결과는 공구 이름 더티 데이터 정제에 있어 해당 도메인 특화 지식의 검색 증강을 활용하여 정확도 높은 데이터 정제를 수행할 수 있음을 보여준다.

나. 모델 효율성 평가

RAG방식을 사용했을 때, Llama-3.2-Korean-Blossom-gguf-3B:Q4_K_M 모델(파라미터 30억, 정확도 97.88%)과 Gemma3:4b 모델(파라미터 40억, 정확도 97.58%)이 EXAONE-Deep-7.8B-GGUF:Q4_K_M 모델(파라미터 78억, 정확도 97.61%)과 유사한 정확도를 달성하였다. 또한 Exaone

3.5:2.4b 모델(파라미터 24억, 정확도 95.26%)보다 Gemma3:1b 모델(파라미터 10억, 정확도 96.75%), EXAONE-4.0-1.2B-GGUF:IQ4_XS 모델(파라미터 12억, 정확도 96.93%)의 정확도가 높다. 이 현상은 LLM의 모델 크기나 컴퓨팅 자원, 도메인 태스크 정확도 간의 상관관계가 RAG 환경에서는 약화됨을 의미한다. 즉, LLM의 임베딩/추론 능력이 충분히 뒷받침되고 검색 품질이 우수하다면, 상대적으로 작은 모델이라도 대형 모델과 대등하거나 더 나은 성능을 낼 수 있다. 시스템의 생산성 및 확장성 측면에서 경량 RAG 모델의 경제적 유효성을 보여준다. RAG 메커니즘이 외부 도메인 지식을 LLM에 명시적으로 제공함으로써, 모델 크기 자체가 주는 이점(방대한 일반 지식 기반 추론 능력)이 약화되고 성능이 평준화되었음을 보여준다. 결과적으로, 도메인 특화된 정제 태스크에서는 LLM의 규모보다 검색된 맥락 및 명령 이행 능력이 더 중요함을 의미한다.

4.2. 생성 속도 및 정확도 트레이드오프 분석

우선, 각 모델 별로 생성을 위해 소요된 시간을 아래 [표5]와 같이 나타내었다. 1~3시간을 ‘빠름’, 3~7시간은 ‘보통’, 7~10은 ‘느림’, 그 이상의 경우에는 ‘매우 느림’으로 범주화하였다.

순위	모델	생성속도 (Hour:Min:Sec)	범주
1	Gemma3:1b	1:15:39	빠름
2	EXAONE-Deep-2.4B-GGUF:Q4_K_M	1:28:53	빠름
3	EXAONE-4.0-1.2B-GGUF:IQ4_XS	1:29:53	빠름
4	EXAONE-Deep-2.4B-GGUF:Q4_BF16	3:40:05	보통
5	Llama-3.2-Korean-Blossom-3B-GGUF:Q2_K	3:54:28	보통
6	EXAONE-Deep-7.8B-GGUF:Q4_K_M	4:48:42	보통
7	Gemma3:4b	7:07:41	느림
8	Exaone 3.5:2.4b	8:13:52	느림
9	Llama-3.2-Korean-Blossom-gguf-3B:Q4_K_M	11:02:52	매우느림
10	EXAONE-4.0-1.2B-GGUF:BF16	12:51:32	매우느림
11	Deepseek-r1:1.5b	13:20:48	매우느림

표 5. 오픈소스 LLM 별 공구이름 더티데이터 정제 생성 속도

다음으로, RAG 시스템의 효율적인 트레이드오프를 분석하기 위해서 먼저 모델의 우선순위 설정을 위한 평가 기준을 다음의 [표6]과 [표7] 같이 정의해보았다.

구분	기준	정량적 범위 (초)	정성적 등급
정확도	$\geq 90\%$	—	사용 가능 (Usable)
	$< 90\%$	—	사용 불가 (Not Usable)
생성 속도	≤ 3 시간	$\leq 10,800$	빠름 (Fast)
	3시간 < Cost $\leq$ 5시간	$\leq 18,000$	보통 (Normal)
	5시간 < Cost $\leq$ 10시간	$\leq 36,000$	느림 (Slow)
	> 10 시간	$> 36,000$	매우 느림 (Very Slow)

표 6. 정확도, 토큰 생성 속도 간 트레이드오프 평가 기준

정확도 조건	생성 속도 조건	최종 트레이드오프 분석
사용 가능 ($\geq 90\%$)	빠름 또는 보통 (≤ 5 시간)	선택 가능한 모델
사용 가능 ($\geq 90\%$)	느림 또는 매우 느림 (> 5 시간)	차순위 모델
사용 불가 ($< 90\%$)	이 외 모든 속도	사용 어려움

표 7. 모델 우선순위 설정 기준

그리고 트레이드 오프를 계산하기 위해 더티데이터의 정제 정확도 (Accuracy)와 답변 생성속도(Cost) 간에 가중치 α 를 도입해 최적의 모델을 탐색해보았다(WINGPT Team, 2025 [2]).

$$\text{Trade-Off Score} = \alpha \times \text{정확도} - (1 - \alpha) \times \text{답변 생성속도}$$

여기서 정확도와 비용은 모델의 정확도, 생성속도 최대치를 기준으로 정규화된 값을 사용한다. 정확도의 경우 높을수록, 답변생성속도는 낮을수록 높은 Trade-Off Score를 갖는다. 가중치 α 의 값에 따라 속도 중심 상황($\alpha = 0.25$), 균형 중심 상황($\alpha = 0.5$), 정확도 중심 상황($\alpha = 0.75$)으로 나타내었다.

순위	LLM 모델	파라미터 (B)	양자화/정밀도	정확도 (%)	생성 시간 (Sec)	Trade-Off Score		
						속도 중심	균형 중심	정확도 중심
						$\alpha = 0.25$	$\alpha = 0.5$	$\alpha = 0.75$
1	Gemma3:1b	1.0	-	96.75	4,539	0.1763	0.447	0.7177
2	EXAONE-4.0	1.2	IQ4_XS	96.93	5,393	0.1634	0.439	0.7147
3	EXAONE-Deep-2.4B	2.4	Q4_KM	81.51	5,319	0.1252	0.361	0.5969
4	EXAONE-Deep-7.8B	7.8	Q4_K_M	97.61	17,322	-0.0211	0.3184	0.6578
5	EXAONE-Deep-2.4B	2.4	Q4_BF16	79.86	13,205	-0.0021	0.2705	0.5432
6	Gemma3:4b	4.0	-	97.58	25,661	-0.1513	0.2314	0.6142
7	Exaone 3.5:2.4b	2.4	-	95.26	29,632	-0.2192	0.1783	0.5757
8	Llama-3.2-Korean-Blossom-3B	3.0	Q2_K	55.91	14,068	-0.0768	0.1392	0.3552
9	Llama-3.2-Korean-Blossom-3B	3.0	Q4_K_M	97.88	39,772	-0.3708	0.0861	0.5431
10	EXAONE-4.0-1.2B	1.2	BF16	94.06	46,292	-0.4823	-0.0012	0.4799
11	Deepseek-r1:1.5b	1.5	-	62.68	48,048	-0.5899	-0.1798	0.2303

표 8. 오픈소스 LLM 모델 Trade-Off Score




그림 7. 정확도-생성속도(Cost) 트레이드 오프 비교 그래프

가. 우선순위 상위 모델 분석

Gemma3:1b, EXAONE-4.0-1.2B-GGUF:IQ4_XS, EXAONE-Deep-7.8B-GGUF:Q4_K_M 세 모델들은 사용 가능한 정확도(90%)를 만족시키면서, 속도 또한 보통 이상(5시간)으로 효율성 기준을 충족한다. (α 값이 0.5 이하인 속도 우선 또는 균형 시나리오에서 기준을 만족)

나. 그 외 모델

앞서 우선순위 상위 모델을 제외한 모델의 경우 [표7]에서 제시한 정확도 조건(< 90%)을 충족하지 못하여 RAG의 핵심 목적인 정확도 높은 정제에서의 기준을 달성할 수 없어 환각 문제 등의 위험이 존재하거나 생성속도가 지나치게 길기 때문에 실용성을 보장하기 어렵다. 특히, Deepseek-r1:1.5b의 경우에는 낮은 파라미터로 빠른 생성시간이 예상되었으나 생성시간이 길고(약 13시간) 낮은 정확도(약 62%)로 우선순위가 낮음을 확인할 수 있다.

모델 (Trade-Off Score, $\alpha = 0.5$)	파라미터 (B)	양자화/ 정밀도	정확도 (%)	생성시간 (Sec)	적합 시나리오
Gemma3 (0.447)	1.0	-	96.75	4,539	속도 우선 가장 낮은 비용으로 높은 정확도 달성 빠른 응답 속도가 필요한 환경
EXAONE-4.0 (0.439)	1.2	IQ4_XS	96.93	5,393	효율 우선 높은 정확도와 속도 측면 모두 균형
EXAONE-Deep (0.3184)	7.8	Q4_K_M	97.61	17,322	정확도 우선 높은 정확도가 필요한 환경

표 9. LLM 모델 크기 대비 생성속도 별 적합 시나리오 제시

정확도와 생성속도 트레이드오프 분석을 통해 가중의 변화와는 거의 무관하게 주요 상위 모델의 성능을 확인할 수 있었으며, 시나리오에 따라 속도, 효율, 정확도 우선의 상황을 [표9]과 같이 나타내었다.

4.3. 더티데이터 유형별 정제 성능 분석

LLM 모델별 더티데이터 13가지 세부 유형에 대한 정제 정확도 분석 결과는 LLM 기반 표준화 알고리즘의 강점 영역과 취약 영역을 명확히 구분하여 보여준다.

모델												
세부 유형	Llama-3.2-Korean-Blossom-3B-gguf:Q4_K_M	EXAO NE-De ep-7.8 B-GGUF:Q4_K_M	Gemma3_4b	EXAO NE-4.0 -1.2B-GGUF:Q4_XS	Gemma3:1b	EXAO NE_3.5:2.4b	EXAO NE-4.0 -1.2B-GGUF:BF16	EXAO NE-De ep-2.4 B-GGUF:Q4_K_M	EXAO NE-De ep-2.4 B-GGUF:Q4_BF16	Deepseek_r1:1.5b	Llama-3.2-Korean-Blossom-3B-gguf:Q2_K	Llama-3.2-Korean-Blossom-3B-gguf:Q4_K_M
속성 기입	0.98	0.99	0.99	0.98	0.98	0.98	0.96	0.88	0.85	0.65	0.34	0.98
동력원 명시	0.97	0.99	0.98	0.97	0.98	0.91	0.97	0.81	0.83	0.49	0.74	0.97
세트/구성품	0.96	0.91	0.94	0.94	0.93	0.85	0.92	0.75	0.70	0.69	0.58	0.96
브랜드 혼입	0.99	0.96	0.99	0.98	0.96	0.97	0.94	0.73	0.75	0.58	0.80	0.99
메타 데이터	0.99	0.99	0.98	0.95	0.96	0.96	0.96	0.84	0.79	0.46	0.42	0.99
오타자	0.92	0.96	0.95	0.97	0.95	0.98	0.95	0.81	0.84	0.59	0.50	0.92
일본어 잔재	1.00	0.99	1.00	1.00	0.97	0.91	1.00	0.60	0.37	0.32	0.69	1.00
복합명사	0.96	0.99	0.94	0.96	0.93	0.92	0.95	0.78	0.76	0.68	0.44	0.96
주/부속품 혼동	1.00	1.00	0.96	0.99	0.98	0.99	0.99	0.74	0.63	0.59	0.65	1.00
특수기호	1.00	1.00	1.00	0.98	0.97	0.92	0.97	0.88	0.90	0.60	0.50	1.00
영문/약어	0.97	1.00	0.93	0.87	0.93	0.90	0.80	0.63	0.57	0.70	0.40	0.97
운영용 텍스트	1.00	1.00	1.00	1.00	0.75	0.88	1.00	0.75	0.88	0.75	0.75	1.00
인코딩 오류	1.00	0.83	1.00	0.50	0.83	0.83	0.50	1.00	1.00	0.33	0.83	1.00

표 10. 더티데이터 유형별 정확도

모델												
세부 유형	Llama-3.2-Korean-Blossom-3B-gguf:Q4_K_M	EXAONE-Deep-7.8B-GGU F:Q4_K_M	Gemma3:4b	EXAONE-4.0-1.2B-G GUF: IQ4_XS	Gemma3:1b	EXAONE_3.5: 2.4b	EXAONE-4.0-1.2B-G GUF: BF16	EXAONE-Deep-2.4B-GGU F:Q4_K_M	EXAONE-Deep-2.4B-GGU F:Q4_BF16	Deepseek_r1:1.5b	Llama-3.2-Korean-Blossom-3B-gguf:Q2_K	FewShot_Evaone_3.5: 2.4b
메타데이터	0.01	0.01	0.02	0.05	0.04	0.04	0.04	0.16	0.21	0.54	0.58	0.51
인코딩 오류	0.00	0.17	0.00	0.50	0.17	0.17	0.50	0.00	0.00	0.67	0.17	0.50
특수기호	0.00	0.00	0.00	0.02	0.03	0.08	0.03	0.12	0.10	0.40	0.50	0.60
운영용 텍스트	0.00	0.00	0.00	0.00	0.25	0.13	0.00	0.25	0.13	0.25	0.25	0.50
복합명사	0.04	0.01	0.06	0.04	0.07	0.08	0.05	0.22	0.24	0.32	0.56	0.86
세트/구성품	0.04	0.09	0.06	0.06	0.07	0.15	0.08	0.25	0.30	0.31	0.42	0.65
주/부속품 혼동	0.00	0.00	0.04	0.01	0.02	0.01	0.01	0.26	0.37	0.41	0.35	0.68
동력원 명시	0.03	0.01	0.02	0.03	0.02	0.09	0.03	0.19	0.17	0.51	0.26	0.59
브랜드 혼입	0.01	0.04	0.01	0.02	0.04	0.03	0.06	0.27	0.25	0.42	0.20	0.45
속성기입	0.02	0.01	0.01	0.02	0.02	0.02	0.04	0.12	0.15	0.35	0.66	0.52
영문/약어	0.03	0.00	0.07	0.13	0.07	0.10	0.20	0.37	0.43	0.30	0.60	0.80
오타자	0.08	0.04	0.05	0.03	0.05	0.02	0.05	0.19	0.16	0.41	0.50	0.81
일본어 잔재	0.00	0.01	0.00	0.00	0.03	0.09	0.00	0.40	0.63	0.68	0.31	0.51

표 11. 더티데이터 유형별 오분류 비율

가. LLM 강점 영역

상위 RAG 모델들은 특수기호, 운영용텍스트, 일본어잔재 유형에서 100%에 가까운 정확도를 기록했다. 운영용 텍스트는 심각한 노이즈에도 불구하고 RAG 모델들은 이러한 노이즈를 식별하고 제거하는 데 매우 우수함을 확인하였다.

나. LLM 취약점 영역

유형별 정확도 분석 결과, 세트/구성품 유형은 모델에 따라 정확도가 하락하며 다른 유형에 비해 상대적으로 큰 취약점을 드러냈다. 이는 의미 모호성이 여전히 LLM 기반 시스템의 데이터 정제에 있어서 근본적인 한계로 작용함을 시사한다.

4.4. 실패사례 진단

정제 전 이름	정답	유형 분류	대표 정제 결과 (모델 예시)	유사도	오류 분석
(1)접톱	톱	메타 데이터	접톱 (EXAONE-4.0:1.2B)	0.88	유사도 높음 목록용 순번 (1)제거 성공 의미적 이해 불일치
HSS쇠톱날	톱날	영문\약어	쇠톱날 (Gemma3:4b)	0.90	유사도 높음 재질 약어 HSS제거 성공 ‘톱날’의 재질특성 정제 실패
몽키스패너 (250mm세신)	몽키스패너	브랜드 혼입	세신 (Llama-3.2)	0.81	의미 추출 실패 주 정보인 ‘몽키스패너’를 추출하지 못하고, 부가 정보인 브랜드 (세신)로 오분류
비트 SDS PLUS 세트	드릴 비트 세트	세트/구성품	드릴비트 (Deepseekr1:1.5b)	0.92	유사도 높음 ‘세트’ 제품을 단품/부속품으로 오분류 ‘드릴비트’라는 핵심 의미는 유지하여 유사도가 높음 판매 단위(SKU) 식별에 실패함
(불가)육각 기리세트	드릴 비트 세트	일본어 잔재/메타 데이터	drill bit set (EXAONE-Deep-2.4B)	0.41	유사도 낮음 관리용 태그 ‘(불가)’ 정제 성공 ‘기리’를 ‘드릴비트’로 표준화하였으나 과정에서 영문으로 출력
임팩트 진동드릴	해머드릴	복합 명사	임 impact drill (EXAONE-Deep-2.4B)	0.20	유사도 낮음 ‘해머드릴’로의 표준화 실패 표준화 과정에서 한글, 영문 혼합으로 잘못 출력

표 12. 더티데이터 유형 별 정제 실패 사례 분석

4.5. LLM기반 정제 시스템의 실증적 의미

더티데이터 정제는 궁극적으로 데이터 분석의 성능을 향상시키기 위한 전제 조건이다. LLM 기반 의미론적 표준화를 통해 의미적으로 동일한 표현들이 하나의 표준 레이블로 완성되면, 원본 데이터의 불필요한 카디널리티(Cardinality)가 크게 감소한다. 이는 데이터 기반 의사결정의 신속성뿐만 아니라, 결과의 신뢰도(Data Quality) 측면에서 LLM 기반 워크플로우의 가능성을 제시하는 핵심적인 요소가 된다.

V. 결론

5.1. 연구 결과 및 시사점

비정형 범주형 공구 더티데이터의 의미론적 표준화 문제를 해결하기 위해 LLM과 RAG 기법을 활용한 알고리즘의 효과성을 정량적으로 검증하였다. 주요 연구 결과는 다음과 같이 요약할 수 있다.

첫째, LLM의 의미론적 추론 능력과 RAG의 도메인 지식 보강을 결합한 방법론이 기존 Few-Shot 방식(39.17%) 대비 압도적인 정확도(최고 97.88%)를 달성함으로써, LLM 기반 데이터 정제 패러다임의 성공적인 전환 가능성을 확인하였다.

둘째, 경량 LLM 모델의 효율성을 확인하였다. RAG 환경에서 소형 모델이 대형 모델 이상의 성능을 발휘함에 따라, LLM 기반 시스템 설계에서 컴퓨팅 자원의 한계를 극복하고 실용화 방향성을 제시하였다.

셋째, LLM은 메타데이터, 특수기호, 운영용 텍스트와 같은 노이즈를 높은 더티데이터를 정확도로 제거할 수 있음을 확인하였다. 이는 데이터 품질을 근본적으로 상향 평준화시킴을 의미한다.

5.2. 제안 알고리즘의 기대 효과

데이터 분석 업무에서 기본 전제로 원데이터의 불완전성에 따라 정제해야 하는 ‘사람’에 의한 데이터 입력 과정의 많은 오류들을 최신 AI 기술을 활용하여 접근해 보는데 의미가 있다. 특히 공공이름 데이터는 이러한 오류가 집약된 굉장히 ‘더러운’ 데이터이기 때문에, 이 데이터를 정제하는 LLM의 정확도와 총 생성 시간(처리 속도)을 확인하는 과정은 데이터 품질 확보의 중요성 보여준다. 이 알고리즘은 데이터 분석

가의 생산성을 극대화하고, 데이터 품질의 상향 평준화를 통해 데이터 기반 의사결정의 신뢰도를 높이는 실질적인 방법론을 제시하였다. 특히, ‘생성 속도’와 ‘정확도’의 트레이드 오프를 통해 최적, 고성능, 최대 처리 세 가지 관점에서의 데이터분석 시스템 적용 방향을 제시함으로써 학문적 및 실증적 기여를 할 수 있다.

5.3. 연구 한계 및 향후 연구 방향

본 연구는 LLM API 사용 시 발생할 수 있는 비용 및 지연 시간 문제, 그리고 LLM의 환각(Hallucination) 현상으로 인한 오류 가능성 등 기존 LLM 기반 연구가 갖는 일반적인 한계를 공유한다. 특히, 연구자가 수동으로 구축하고 수정한 정답지 데이터 및 더티데이터 유형 분류 과정이 실제 LLM 모델이 학습했을 빅데이터와 상이한 부분이 있었을 것으로 판단되며, 이는 정확도 측면에서 영향을 미쳤을 수 있다.

향후 연구는 다음과 같은 방향으로 진행될 필요가 있다.

첫째, 정제 과정에서 취약점을 보인 의미 모호형 데이터에 대해 LLM의 추론 결과를 보강할 수 있도록 명시적인 비즈니스 규칙 또는 인간 피드백 루프(Human-in-the-Loop)를 시스템에 통합하는 연구가 필요하다.

둘째, RAG 시스템 구축 시 사용된 임베딩 모델 외 다양한 한국어 모델을 활용하여 성능 및 효율성을 비교 분석함으로써, LLM 기반 표준화 알고리즘의 일반화 가능성과 자원 효율성을 더욱 강화해야한다.

참 고 문 헌

- [1] Wong, M., Alshehri, A., Kao, S., & He, H. (2025), 'PolyNorm: Few-Shot LLM-Based Text Normalization for Text-to-Speech', *arXiv preprint arXiv:2511.03080*.
- [2] WINGPT Team (2025), 'BEYOND BENCHMARKS: THE ECONOMICS OF AI INFERENCE', *arXiv preprint arXiv:2510.26136*.
- [3] Dhakal, A., Paudel, K., & Sigdel, S. (2025), 'An Artificial Intelligence Driven Semantic Similarity-Based Pipeline for Rapid Literature Review', *arXiv preprint arXiv:2509.15292*.
- [4] Wang, Y., Chen, Y., Li, H., Mo, W., Wen, P., Xu, C., Luo, Y., Li, C., Du, L., Jiang, Q., Wang, Y., Mao, X., Ma, M., Gao, F., Kumar, S., Park, T., & Song, Y. (2025), 'CSRM-LLM: Embracing Multilingual LLMs for Cold-Start Relevance Matching in Emerging E-commerce Markets', *arXiv preprint arXiv:2509.01566*.
- [5] Amugongo, L. M., Mascheroni, P., Brooks, S., Doering, S., & Seidel, J. (2025), 'Retrieval augmented generation for large language models in healthcare: A systematic review', *「PLOS Digital Health」*, 4(6), e0000877.
- [6] GAN, A., YU, H., ZHANG, K., LIU, Q., YAN, W., HUANG, Z., TONG, S., CHEN, E., & HU, G. (2025), 'Retrieval Augmented Generation Evaluation in the Era of Large Language Models: A Comprehensive Survey', *arXiv preprint arXiv:2504.14891*.
- [7] Belcak, P., Heinrich, G., Muralidharan, S., Diao, S., Fu, Y., Dong, X., Lin, Y. C., & Molchanov, P. (2025), 'Small Language Models are the Future of Agentic AI', *arXiv preprint arXiv:2506.02153*.
- [8] Campo, D. N., Conde, J., Alonso, Á., Huecas, G., Salvachúa, J., & Reviriego, P. (2025), 'Real-time Spatial Retrieval Augmented Generation for Urban Environments', *arXiv preprint arXiv:2505.02271*.
- [9] Yewon Hwang, Sungbum Jung, Hanwool Lee, Sara Yu, (2025), 'What Advantages Can Low-Resource Domain-Specific Embedding Model Bring? -- A Case Study on Korea Financial Texts', *arXiv preprint arXiv:2502.07131*.

- [10] Glock, A. C., & Korom, P. (2025), 'Detecting and Cleaning Errors in Personal Contact Information with Large Language Models', *Software Competence Center Hagenberg GmbH & Austrian Post*.
- [11] Saparina, I., & Lapata, M. (2024), 'AMBROSIA: A Benchmark for Parsing Ambiguous Questions into Database Queries', *arXiv preprint arXiv:2406.19073*.
- [12] Zhang, S., & Huang, Z. (2024), 'Data Cleaning Using Large Language Models', *arXiv preprint arXiv:2410.15547*.
- [13] Karaca, M. F. (2024), 'Effects of Preprocessing on Text Classification in Balanced and Imbalanced Datasets', *KSII Transactions on Internet and Information Systems*, 18(3), 591-602.
- [14] 정선우, 임동혁, 안진현 (2023), '오염된 훈련데이터가 거대언어모델의 출력에 미치는 영향 분석', *인터넷전자상거래연구*, 23(6), 1-10.
- [15] Nguyen, A. T. H., Nguyen, D. H., Nguyen, N. T., Ho, K. T. D., & Nguyen, K. V. (2023), 'Automatic Textual Normalization for Hate Speech Detection', *arXiv preprint arXiv:2311.06851*.
- [16] Ovadia, O., Brief, M., Mishaeli, M., & Elisha, O. (2023), 'Fine-Tuning or Retrieval? Comparing Knowledge Injection in LLMs', *arXiv preprint arXiv:2312.05934*.
- [17] Christian, N., & Okorie, C. (2013), 'Influence of product attributes on consumers' purchase decision in the Malt market in Enugu state, Nigeria', *Journal of Business Research*, 16(2), 1-24.
- [18] Kim, W., Choi, B. J., Hong, E. K., Kim, S. K., & Lee, D. (2003), 'A Taxonomy of Dirty Data', *Journal of Data Management*, 1(1), 1-24.
- [19] Keeney, R. L. (1975), 'MULTIATTRIBUTE UTILITY ANALYSIS: A BRIEF SURVEY', *Research Memoranda*, RM-75-43, IIASA

이 력 서

성 명 : 신 홍 철

생년월일 : 1991년 2월 19일

학 력

2011 ~ 2017 건국대학교 기계공학과

경 력

2019 ~ 2024 GS E&R(GS반월열병합발전)